

# TIF Redes

Garcia Justo

## 1 Análisis de IPs reportadas como atacantes por SSH

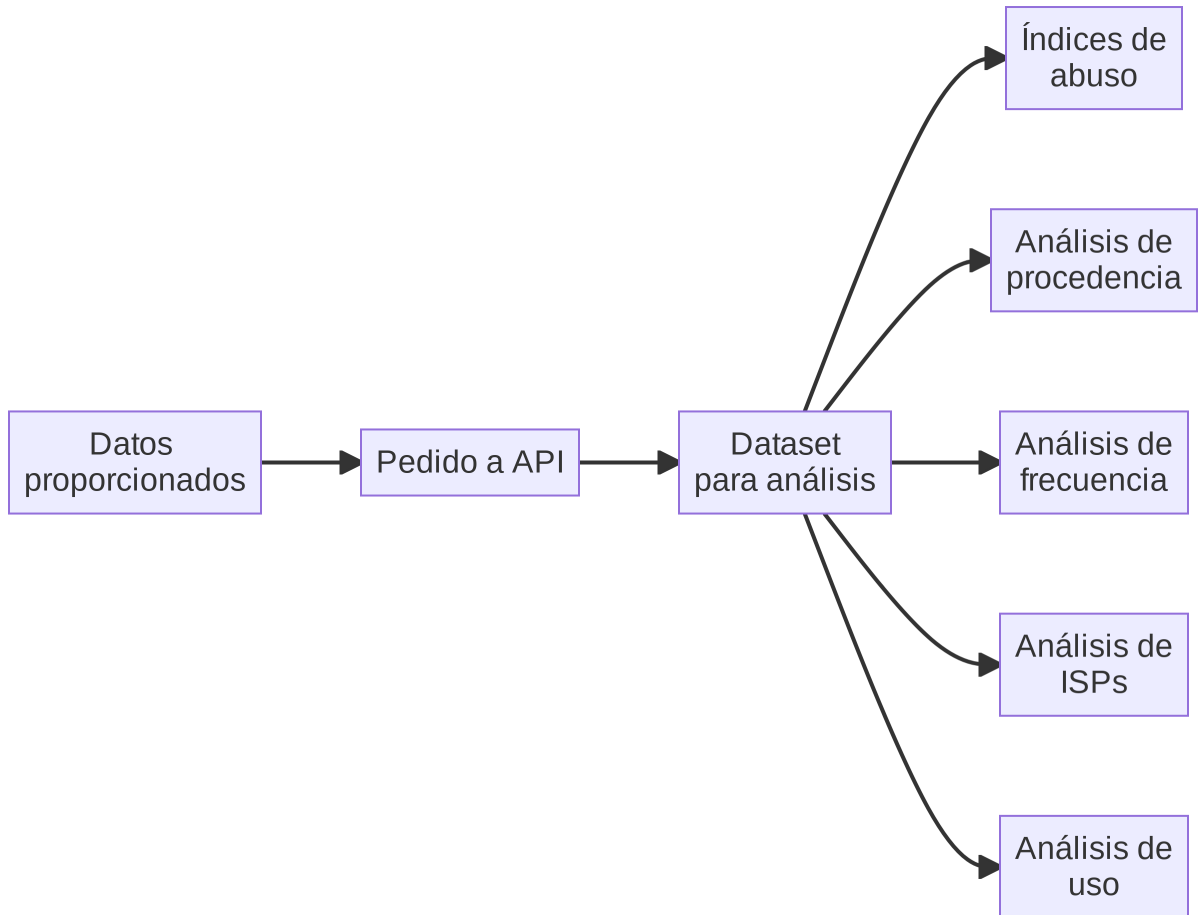
Los ataques por SSH (Secure Shell) son intentos maliciosos de comprometer un sistema a través del protocolo SSH.



Figure 1: Protocolo SSH

SSH es muy utilizado porque permite establecer una conexión segura y cifrada entre un cliente y un servidor. Pero, establecida la conexión, puede ser también aprovechado por los atacantes.

Al proporcionarse esta información no se especificó la naturaleza del ataque, pero entre los más comunes están los de fuerza bruta.



## 1.1 Extracción de IPs

Para la realización de este análisis contaba con una lista de IPs que fueron reportadas por conexiones SSH y ataques DDoS. En este caso extraeré las IPs de SSH haciendo uso de bash y Python.

```
patron = "[0-9]{1,3}\.[0-9]{1,3}\.[0-9]{1,3}\.[0-9]{1,3}"  
!grep -Eo "$patron" data/SSH.txt > data/IPsSSH.txt
```

```
with open("data/IPsSSH.txt") as ips:  
    ipSSH = ips.read()  
  
ipSSH = ipSSH.replace("\n", " ").split()
```

ipSSH

```
['54.144.244.57',  
 '188.166.216.223',  
 '220.94.228.162',  
 '218.92.0.99',  
 '116.193.159.2',  
 '109.117.92.13',  
 '167.99.112.43',  
 '89.248.163.219',  
 '143.198.204.177',  
 '61.177.173.45',  
 '8.222.204.225',  
 '220.135.119.188']
```

### 1.1.1 Importamos la implementación de las peticiones a la API

```
!cp ../app/modulos/abuseIPDB.py modulos/abuseIPDB.py
```

```
#Importo los modulos necesarios  
from modulos.abuseIPDB import AbuseIPDB  
import pandas as pd
```

```
#Construyo el objeto  
apiAbuse = AbuseIPDB()
```

```
import os  
import seaborn as sns
```

```
#Declaro las keys de la info que devuelve mi implementación de requests  
keys = ['esPublica', 'estaEnWhitelist', 'scoreAbuso', 'pais', 'codigoPais', 'isp', 'tipoDe
```

```
diccDf = {'ip' : []}
```

```
if os.path.isfile("data/ipSSH.csv"):
```

```
    df = pd.read_csv("data/ipSSH.csv")
```

```
else:
```

```

for ip in ipSSH:
    diccDf['ip'].append(ip)
    info = apiAbuse.getInfo(ip)
    for key in keys:
        if key in diccDf:
            diccDf[key].append(info[key])
        else:
            diccDf[key] = [info[key]]

df = pd.DataFrame(data=diccDf)

```

```
pd.DataFrame(df.columns)
```

Table 1: Columnas del DataFrame construido a partir de la información solicitada del servidor

0	
0	ip
1	esPublica
2	estaEnWhitelist
3	scoreAbuso
4	pais
5	codigoPais
6	isp
7	tipoDeUso
8	ultimoReporte

Listé en Table 1 la información que obtuve de la base de datos de AbuseIPDB para cada IP.

```
df.head(3)
```

	ip	esPublica	estaEnWhitelist	scoreAbuso	pais	codigoPais	isp
0	54.144.244.57	True	False	55	NaN	US	Amazon Data Services N
1	188.166.216.223	True	False	100	NaN	SG	DigitalOcean LLC
2	220.94.228.162	True	False	100	NaN	KR	KT Corporation

```

unameds = [i for i in df.columns if 'Unnamed' in i]
for i in unameds:
    df.drop(i, axis=1, inplace=True)

```

```
df.to_csv("data/ipSSH.csv", index=False)
```

## 1.2 Índices de abuso

```
recuento = df["scoreAbuso"].value_counts().to_dict()

pd.DataFrame(data={"Score": list(recuento.keys()), "Reportes": list(recuento.values())})
```

Table 3: Indice de abuso y las veces que se repite

	Score	Reportes
0	100	11
1	55	1

Como se puede apreciar en la tabla de arriba (Table 3), han sido múltiples veces reportadas por distintos usuarios a lo largo del mundo. Esto hace que la base de datos las califique con un score de abuso alto. Por lo tanto, tenemos la certeza de que son IPs que han sido utilizadas con fines malintencionados previamente y que quien proporcionó los datos no fue el único afectado.

## 1.3 Análisis de procedencia

```
import geopandas as gpd
import matplotlib.pyplot as plt
import plotly.express as px
import numpy as np
import pycountry

df['pais'] = df['codigoPais'].apply(lambda codigo: pycountry.countries.get(alpha_2=codigo))
dfgdp = df.copy()
dfgdp['codigoPais'] = df['pais'].apply(lambda nombre: pycountry.countries.search_fuzzy(nombre))

mapa = gpd.read_file(gpd.datasets.get_path('naturalearth_lowres'))
```

### **i** Note

Todas estas librerías utilizan convenciones, por lo cual es importante chequear que estén presentes todos los países que queremos plotear

```
print(np.unique(dfgdp["codigoPais"].loc[~dfgdp["codigoPais"].isin(mapa["iso_a3"])]))
```

```
['HKG' 'SGP']
```

Pude notar que tanto Hong Kong, como Singapur no están representadas en el mapa mundi por ser ciudades. Por ello, debo cargarlas desde otro dataset para marcarla.

En Figure 2 se presenta el mapamundi con los países o ciudades-estado de donde provienen los ataques pintados de rojo y azul respectivamente.

```
paísesMarcados = mapa[mapa['iso_a3'].isin(dfgdp["codigoPais"])]

fig, ax = plt.subplots(figsize=(15, 10))

mapa.plot(ax=ax, edgecolor='grey', color='lightgrey')
paísesMarcados.plot(ax=ax, edgecolor='black', color='red')

ciudades = gpd.read_file(gpd.datasets.get_path('naturalearth_cities'))

singapur = ciudades[ciudades['name'] == 'Singapore']
hongkong = ciudades[ciudades['name'] == 'Hong Kong']

singapur.plot(ax=ax, edgecolor='black', color='blue')
hongkong.plot(ax=ax, edgecolor='black', color='blue')

plt.show()
```

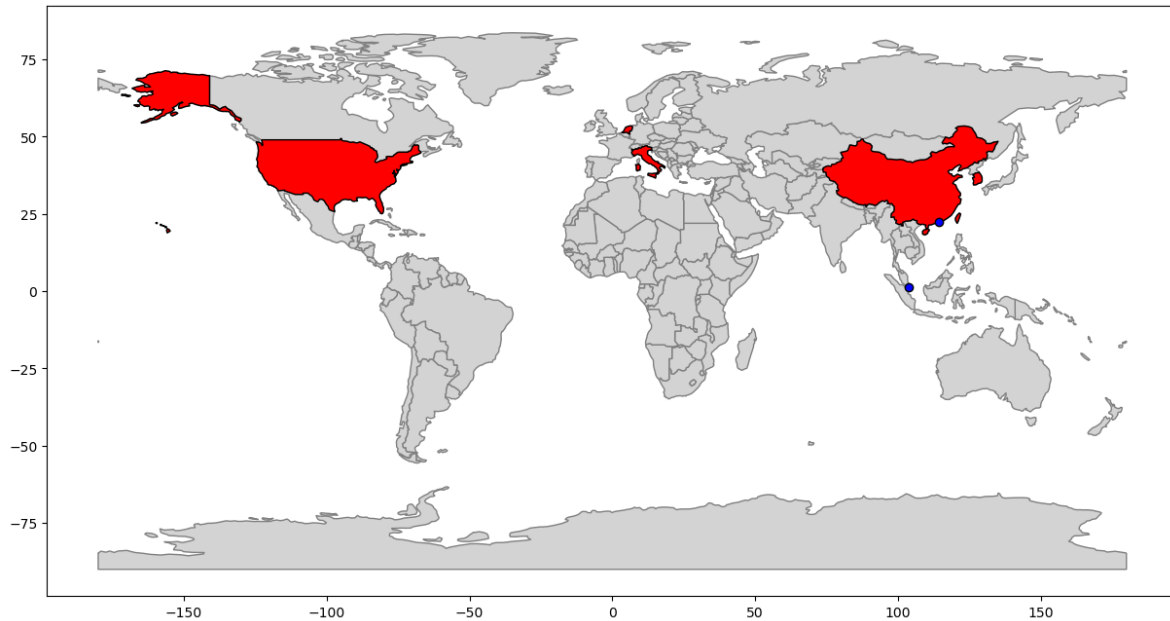


Figure 2: Mapa con los lugares del que proceden las IPs

En la siguiente figura (Figure 3), se puede apreciar el número de IPs que pertenecen a cada uno de los países, con Singapur encabezando la lista.

```
counts = dfgdp["codigoPais"].value_counts().rename_axis('pais').to_frame('counts')
counts.reset_index(level=0, inplace=True)

counts = counts.sort_values(by='counts')

fig, ax = plt.subplots(figsize=(8,6))

bars = plt.barh(counts["pais"], counts['counts'], color='#ef9f76')

ax.spines[['right', 'top', 'bottom']].set_visible(False)
ax.xaxis.set_visible(False)

ax.spines['left'].set_color('black')

ax.tick_params(axis='y', colors='black')
ax.bar_label(bars, color='black')
plt.tight_layout()
plt.show()
```




Figure 3: Recuento del número de reportes

```
recuento = df["pais"].value_counts().to_dict()

pd.DataFrame(data={"Pais": list(recuento.keys()), "Reportes": list(recuento.values())})
```

	Pais	Reportes
0	Singapore	3
1	United States	2
2	China	2
3	Korea, Republic of	1
4	Hong Kong	1
5	Italy	1
6	Netherlands	1
7	Taiwan, Province of China	1



## 1.4 Análisis de frecuencia

Definí esta tarea para así, tratar de identificar cierto patron asociado a la hora de ataque.

### 1.4.1 Extracción de información

```
patron = "[0-9]{1,3}\.[0-9]{1,3}\.[0-9]{1,3}\.[0-9]{1,3}"
!grep -Eo "$patron" data/SSH.txt > data/IPsSSH.txt
```

```
patron = "[a-z]{3}\/[0-9]{2}\/[0-9]{4}"
!grep -Eo "$patron" data/SSH.txt >> data/IPsSSH.txt
```

```
patron = "[0-9]{2}\:[0-9]{2}\:[0-9]{2}"
!grep -Eo "$patron" data/SSH.txt >> data/IPsSSH.txt
```

```
with open("data/IPsSSH.txt") as ips:
    data = ips.read()
    data = data.replace("\n", " ").split()
```

```
for i in range(int(len(data)/3)):
    data[i] = data[i] + " " + data[int(len(data)/3)+i] + " " + data[(int(len(data)/3))*2+i]
```

```
data = data[:int(len(data)/3)]
```

```
from datetime import datetime, time
diccInfo = {
    "IP": [],
    "Fecha": [],
    "Hora": []
}
eventos = []
```

```
for i in data:
    diccInfo["IP"].append(i.split()[0])
    diccInfo["Fecha"].append(i.split()[1])
    mes = 5
    dia = int(i.split()[1].split(sep="/")[1])
    año = int(i.split()[1].split(sep="/")[2])
    h = int(i.split()[2].split(sep=":")[0])
```

```

m = int(i.split()[2].split(sep=":")[1])
s = int(i.split()[2].split(sep=":")[2])
diccInfo["Hora"].append(time(hour=int(h), minute=int(m), second=int(s)))
#diccInfo["Hora"].append(i.split()[2])

eventos.append((i.split()[0],datetime(year=año, month=mes, day=dia, hour=h, minute=m)))

dfHora = pd.DataFrame(data=diccInfo)

dfHora["Pais"] = None
for index, row in dfHora.iterrows():
    ip = row["IP"]
    row["Pais"] = df[df['ip'] == ip].iloc[0]['pais']

fig, ax = plt.subplots()

fecha = [evento[1] for evento in eventos]
etiquetas = [evento[0] for evento in eventos]
ax.eventplot(fecha, lineoffsets=0.1, linelengths=0.1, color='r')
ax.set_ylabel(None)
ax.set_yticklabels([])
ax.set_xlim(datetime(2023, 5, 23, 0, 0), datetime(2023, 5, 23, 23, 59))
fig.autofmt_xdate()

```




Figure 4: Visualización de eventos de SSH

En Figure 4 busqué representar los eventos en función del tiempo y podemos ver, que el sistema atacado registró estas IPs en un solo día (23 de Mayo) durante horas de la mañana.

## 1.5 Análisis de ISPs

Table 5 muestra cuantos de los reportes corresponden a cada uno de los proveedores de internet.

```
recuento = df["isp"].value_counts().to_dict()

recuento = pd.DataFrame(data={"ISP": list(recuento.keys()), "Reportes": list(recuento.values())})
recuento
```

Table 5: Número de IPs reportadas de cada ISP

	ISP	Reportes
0	DigitalOcean LLC	3
1	ChinaNet Jiangsu Province Network	2
2	Amazon Data Services NoVa	1
3	KT Corporation	1
4	Pacswitch Globe Telecom Limited	1
5	Vodafone Italia S.p.A.	1
6	FiberXpress BV	1
7	Alibaba.com Singapore E-Commerce Private Limited	1
8	Chunghwa Telecom Co. Ltd.	1

```

counts = df["isp"].value_counts().rename_axis('isp').to_frame('counts')
counts.reset_index(level=0, inplace=True)

counts = counts.sort_values(by='counts')

fig, ax = plt.subplots(figsize=(8,6))

bars = plt.barh(counts["isp"], counts['counts'], color='#ef9f76')

ax.spines[['right', 'top', 'bottom']].set_visible(False)
ax.xaxis.set_visible(False)

ax.spines['left'].set_color('black')

ax.tick_params(axis='y', colors='black')
ax.bar_label(bars, color='black')
plt.tight_layout()
plt.show()

```




Figure 5: Recuento del número de veces que fue reportado un ISP

Figure 5 muestra un recuento de los distintos ISPs que tienen asignadas las IPs.

## 1.6 Análisis de uso

Table 6 muestra el número de veces que fue declarado cierto uso de una IP.

```
recuento = df["tipoDeUso"].value_counts().to_dict()

recuento = pd.DataFrame(data={"uso": list(recuento.keys()), "Reportes": list(recuento.values())})
recuento
```

Table 6: Recuento de usos declarados por las IPs

	uso	Reportes
0	Data Center/Web Hosting/Transit	8
1	Fixed Line ISP	1

```

counts = df["tipoDeUso"].value_counts().rename_axis('uso').to_frame('counts')
counts.reset_index(level=0, inplace=True)

counts = counts.sort_values(by='counts')

fig, ax = plt.subplots(figsize=(8,6))

bars = plt.barh(counts["uso"], counts['counts'], color='#ef9f76')

ax.spines[['right', 'top', 'bottom']].set_visible(False)
ax.xaxis.set_visible(False)

ax.spines['left'].set_color('black')

ax.tick_params(axis='y', colors='black')
ax.bar_label(bars, color='black')
plt.tight_layout()
plt.show()

```

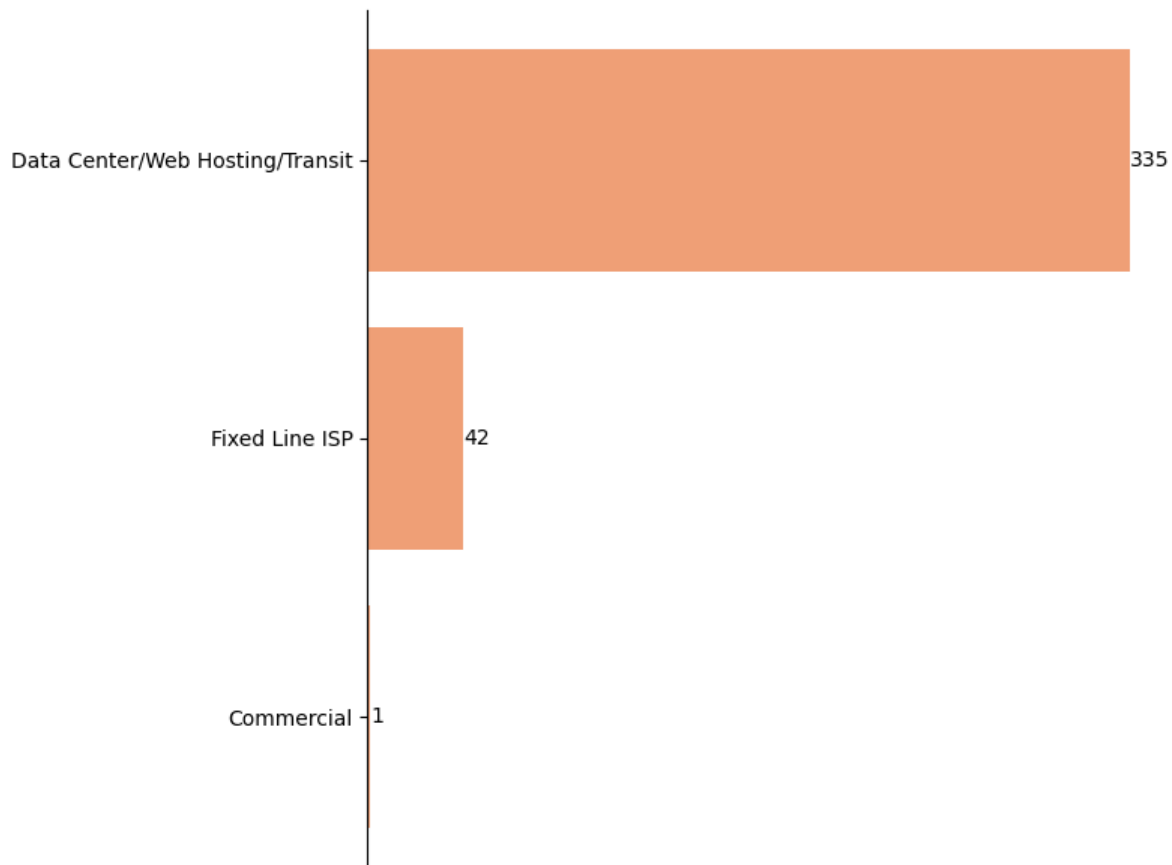


Figure 6: Recuento de los usos que se les da a las IPs

Figure 6 permite visualizar los usos declarados de las IPs declarados.

## 2 Análisis de IPs reportadas por ataque DDoS

Los ataques de denegación de servicio distribuido (DDoS), son intentos de saturar los recursos de un sistema o red, sobrecargando la red con tráfico inesperado.

El foco no es infiltrarse o robar información, sino que busca abrumar y colapsar el objetivo mediante grandes volúmenes de solicitudes.

La característica distintiva de estos ataques es que son “distribuidos”. No se realiza desde una única fuente, sino que se usan múltiples dispositivos como atacantes.


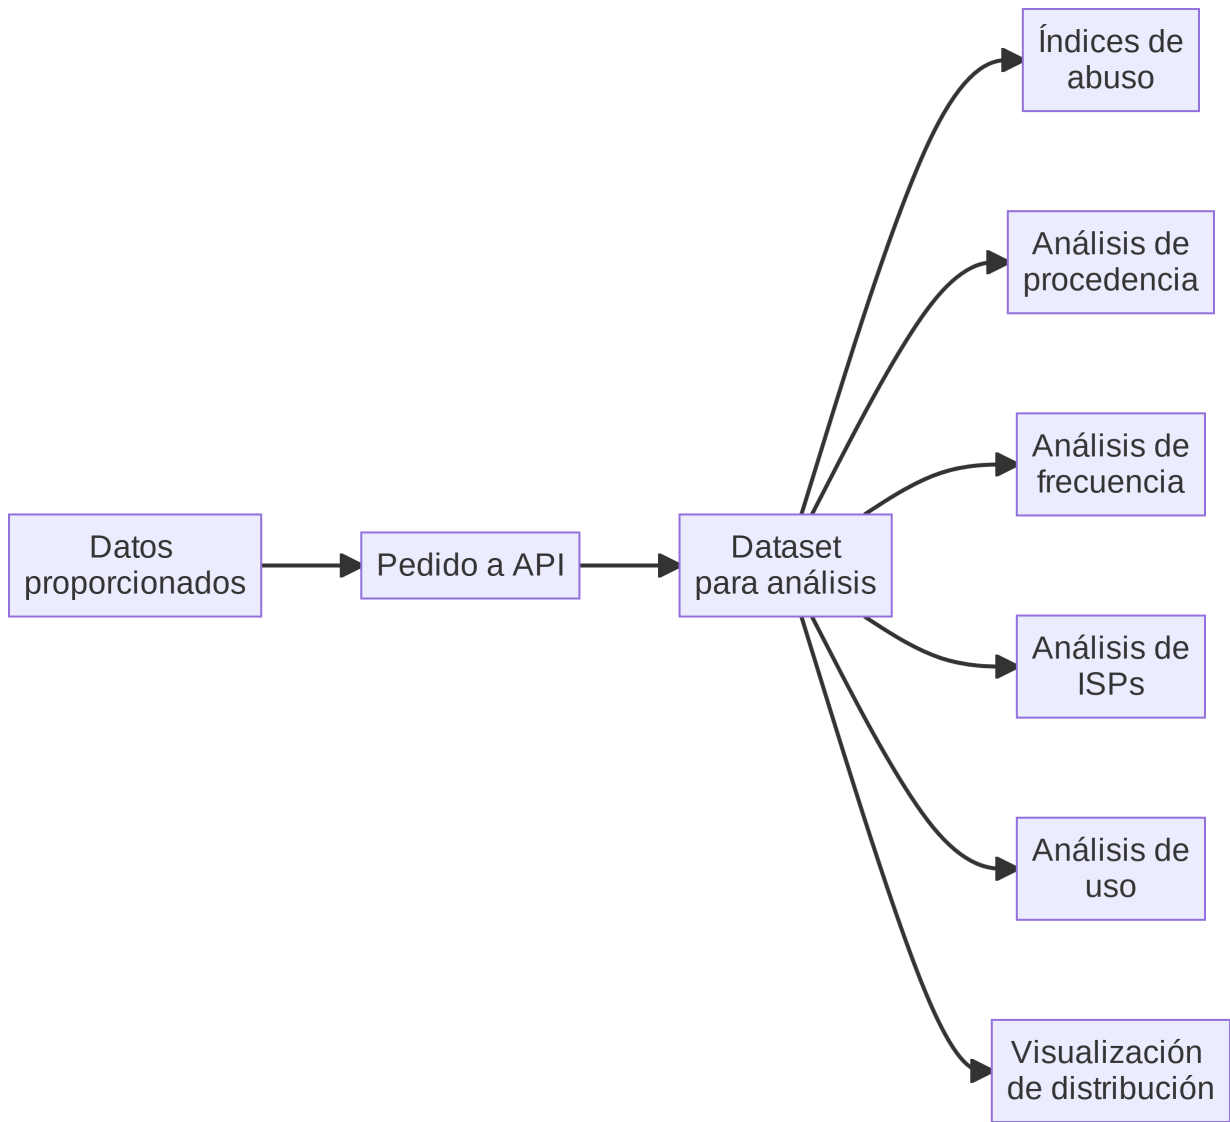


Figure 7: Ilustración ataque DDoS (Cloudflare, 2023)

Lo más probable es que quién reporto estas IPs como atacantes haya detectado grandes volúmenes o picos de solicitudes en un corto tiempo, levantando sospechas que se podría tratar de atacantes.

Para intentar extraer información de los datos definí el siguiente flujo de trabajo:





## 2.1 Extracción de información

```
patron = "[0-9]{1,3}\.[0-9]{1,3}\.[0-9]{1,3}\.[0-9]{1,3}"
!grep -Eo "$patron" data/DDoS.txt > data/IPsDDoS.txt

patron = "[a-z]{3}\/[0-9]{2}\/[0-9]{4}"
!grep -Eo "$patron" data/DDoS.txt >> data/IPsDDoS.txt
```

```

patron = "[0-9]{2}\:[0-9]{2}\:[0-9]{2}"
!grep -Eo "$patron" data/DDOS.txt >> data/IPsDDoS.txt

with open("data/IPsDDoS.txt") as ips:
    data = ips.read()
    data = data.replace("\n", " ").split()

ips = []
dia = []
hora = []
for i in range(int(len(data)/3)):
    ips.append(data[i])
    dia.append(data[int(len(data)/3)+i])
    hora.append(data[(int(len(data)/3))*2+i])
    data[i] = data[i] + " " + data[int(len(data)/3)+i] + " " + data[(int(len(data)/3))*2+i]

data = data[:int(len(data)/3)]

data = pd.DataFrame(data={'ip': ips,
                        'dia': dia,
                        'hora': hora})

apiAbuse = AbuseIPDB()

#Declaro las keys de la info que devuelve mi implementación de requests
keys = ['esPublica', 'estaEnWhitelist', 'scoreAbuso', 'pais', 'codigoPais', 'isp', 'tipoDe

diccDf = {'ip' : []}

if os.path.isfile("data/ipDDOS.csv"):

    df = pd.read_csv("data/ipDDOS.csv")

else:
    for ip, i in zip(ips, range(len(ips))):
        clear_output()
        print(f"{i}/{len(ips)}")
        diccDf['ip'].append(ip)
        info = apiAbuse.getInfo(ip)
        for key in keys:

```

```

        if key in diccDf:
            diccDf[key].append(info[key])
        else:
            diccDf[key] = [info[key]]

    df = pd.DataFrame(data=diccDf)

df["hora"] = data["hora"]
df["dia"] = data["dia"]

unameds = [i for i in df.columns if 'Unnamed' in i]
for i in unameds:
    df.drop(i, axis=1, inplace=True)

df.to_csv("data/ipDDOS.csv", index=False)

```

## 2.2 Índices de abuso

```

recuento = df["scoreAbuso"].value_counts().to_dict()

pd.DataFrame(data={"Score de abuso": list(recuento.keys()), "Reportes": list(recuento.values())})

```

Table 7: Indice de abuso y las veces que se repite

	Score de abuso	Reportes
0	0	375
1	2	2
2	10	1

Contrariamente de lo esperado, en Table 7, puedo observar que la gran mayoría tienen un score de abuso nulo y las que no, es muy bajo.

Lo más simple sería pensar que estas IPs no hayan atacado a más usuarios, pero considero que es poco probable. Por otro lado, podría deberse a la distribución de este ataque, haciendo que en otros sistemas vulnerados pase desapercibido. Otra opción es que el sistema que los reporto tenga mecanismos deficientes para la detección de posibles ataques.

## 2.3 Análisis de procedencia

```
import pycountry
import geopandas as gpd
import matplotlib.pyplot as plt
df['pais'] = df['codigoPais'].apply(lambda codigo: pycountry.countries.get(alpha_2=codigo))
dfgdp = df.copy()
dfgdp['codigoPais'] = df['pais'].apply(lambda nombre: pycountry.countries.search_fuzzy(nombre))

mapa = gpd.read_file(gpd.datasets.get_path('naturalearth_lowres'))

print(np.unique(dfgdp["codigoPais"].loc[~dfgdp["codigoPais"].isin(mapa["iso_a3"])]))
```

['HKG']

En Figure 8 podemos observar el mapamundi y los países o ciudades-estado de donde provienen las IPs coloreados.

```
paísesMarcados = mapa[mapa['iso_a3'].isin(dfgdp["codigoPais"])]

fig, ax = plt.subplots(figsize=(15, 10))

mapa.plot(ax=ax, edgecolor='grey', color='lightgrey')
paísesMarcados.plot(ax=ax, edgecolor='black', color='red')

ciudades = gpd.read_file(gpd.datasets.get_path('naturalearth_cities'))

hongkong = ciudades[ciudades['name'] == 'Hong Kong']

hongkong.plot(ax=ax, edgecolor='black', color='blue')

plt.show()
```

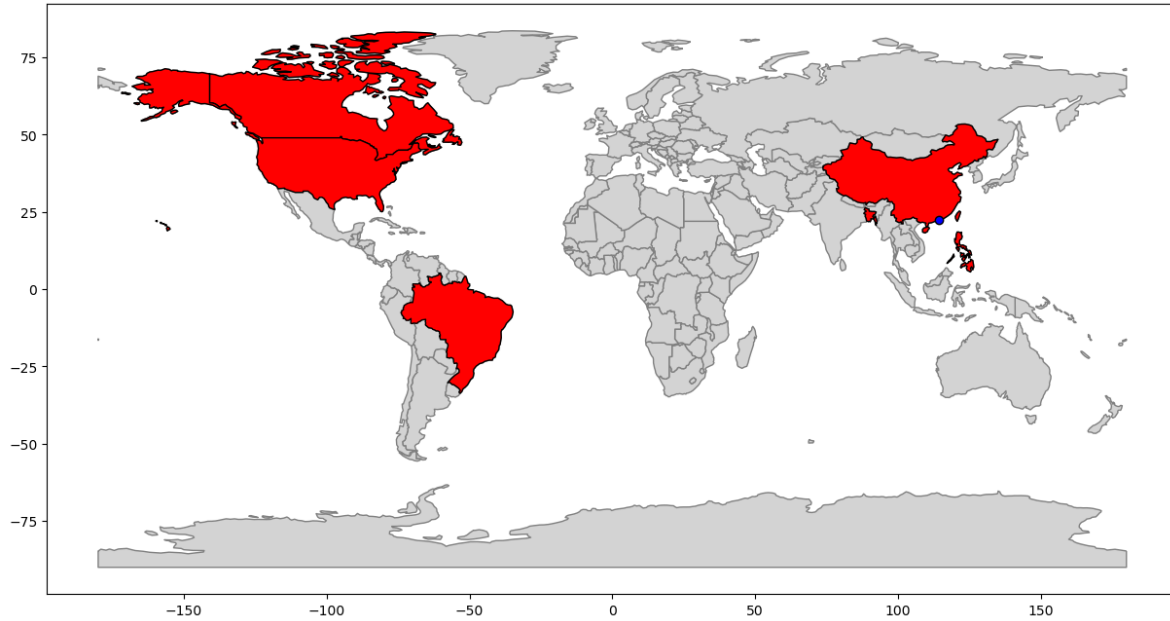


Figure 8: Mapa con los lugares del que proceden las IPs

En la siguiente tabla (Table 8), se puede apreciar el número de IPs que pertenecen a cada uno de los países y una representación gráfica de ello para tener una mejor noción (Figure 9).

```
recuento = df["pais"].value_counts().to_dict()

pd.DataFrame(data={"Pais": list(recuento.keys()), "Reportes": list(recuento.values())})
```

Table 8: Número de IPs que corresponden a cada país.

	Pais	Reportes
0	Hong Kong	174
1	Philippines	118
2	China	75
3	United States	5
4	Canada	3
5	Bangladesh	1
6	Taiwan, Province of China	1
7	Brazil	1

```
counts = df["pais"].value_counts().rename_axis('pais').to_frame('counts')
counts.reset_index(level=0, inplace=True)

counts = counts.sort_values(by='counts')

fig, ax = plt.subplots(figsize=(8,6))

bars = plt.barh(counts["pais"], counts['counts'], color='#ef9f76')

ax.spines[['right', 'top', 'bottom']].set_visible(False)
ax.xaxis.set_visible(False)

ax.spines['left'].set_color('black')

ax.tick_params(axis='y', colors='black')
ax.bar_label(bars, color='black')
plt.tight_layout()
plt.show()
```




Figure 9: Número de reportes por país

## 2.4 Análisis de frecuencia

Al igual que con los ataques SSH, realicé este parso para tratar de identificar cierto patrón asociado a la hora de ataque.

### 2.4.1 Extracción de información

```
eventosDDoS = []
for index, row in df.iterrows():
    fecha = row["dia"].split(sep="/")
    if fecha[0] != 'may':
        print(fecha[0])
    else:
```

```

        mes = 5

    dia = fecha[1]
    año = fecha[2]

    tiempo = row["hora"].split(sep=":")
    hora = tiempo[0]
    minuto = tiempo[1]
    eventosDDoS.append((row["ip"], datetime(int(año), int(mes), int(dia), int(hora), int(minuto))))

fig, ax = plt.subplots()

fecha = [evento[1] for evento in eventosDDoS]
etiquetas = [evento[0] for evento in eventosDDoS]
ax.eventplot(fecha, lineoffsets=0.1, linelengths=0.1, color='r')
ax.set_ylabel(None)
ax.set_yticklabels([])
ax.set_xlim(datetime(2023, 5, 22, 23, 0), datetime(2023, 5, 23, 0, 0))
fig.autofmt_xdate()

```






Figure 10: Visualización de eventos de DDoS

En Figure 10 se puede observar la sucesión de eventos reportados por el denunciante. Pareciese ser una sola línea, pero en realidad es que como se intenta sobrecargar, todas envían datos en un tiempo reducido.

Del gráfico podemos identificar que se recibieron las conexiones el 22 de Mayo rondando las 23:50 horas.

## 2.5 Análisis de ISPs

```
recuento = df["isp"].value_counts().to_dict()

recuento = pd.DataFrame(data={"ISP": list(recuento.keys()), "Reportes": list(recuento.values())})
recuento
```

	ISP	Reportes
0	Suniway Group Limited	75
1	Gold Experience Cloud LLC	75

	ISP	Reportes
2	Dragon Spirit Investments International Co. Li...	73
3	WTW Hightech Company Inc	67
4	Suniway Telecom	39
5	Suniway Group of Companies Inc.	36
6	Intercontinental Internet Data Corp	1
7	Bell Canada	1
8	Comcast Cable Communications LLC	1
9	Cabo Servicos de Telecomunicacoes Ltda	1
10	Shaw Communications Inc.	1
11	Delta DCCNet High Speed Internet	1
12	Nexus Bytes LLC	1
13	Dot Internet	1
14	VPSquan L.L.C.	1
15	Kurun Cloud Inc	1
16	Shine Telecom Co. Ltd.	1
17	CTG Server Ltd.	1
18	Reliablesite.net LLC	1

```

counts = df["isp"].value_counts().rename_axis('ISP').to_frame('counts')
counts.reset_index(level=0, inplace=True)

counts = counts.sort_values(by='counts')

fig, ax = plt.subplots(figsize=(8,6))

bars = plt.barh(counts["ISP"], counts['counts'], color='#ef9f76')

ax.spines[['right', 'top', 'bottom']].set_visible(False)
ax.xaxis.set_visible(False)

ax.spines['left'].set_color('black')

ax.tick_params(axis='y', colors='black')
ax.bar_label(bars, color='black')
plt.tight_layout()
plt.show()

```




Figure 11: Número de veces que se denunció un ISP por ataque DDoS

## 2.6 Análisis de uso

```
recuento = df["tipoDeUso"].value_counts().to_dict()

recuento = pd.DataFrame(data={"uso": list(recuento.keys()), "Reportes": list(recuento.values())})
recuento
```

	uso	Reportes
0	Data Center/Web Hosting/Transit	335
1	Fixed Line ISP	42
2	Commercial	1

```
counts = df["tipoDeUso"].value_counts().rename_axis('tipoDeUso').to_frame('counts')
counts.reset_index(level=0, inplace=True)

counts = counts.sort_values(by='counts')


fig, ax = plt.subplots(figsize=(8,6))

bars = plt.barh(counts["tipoDeUso"], counts['counts'], color='#ef9f76')

ax.spines[['right', 'top', 'bottom']].set_visible(False)
ax.xaxis.set_visible(False)

ax.spines['left'].set_color('black')

ax.tick_params(axis='y', colors='black')
ax.bar_label(bars, color='black')
plt.tight_layout()
plt.show()
```



## 2.7 Visualización de la “distribución”

```
import netaddr

def convertirIP(ip):
    return int(netaddr.IPAddress(ip))

datetimes = [evento[1] for evento in eventosDDoS]
dicc = {"ip": df["ip"],
        "datetime": datetimes}

dfClusters = pd.DataFrame(dicc)
#Realizo una conversión de datetime a tipo de dato continuo
dfClusters["datetime"] = dfClusters["datetime"].apply(lambda x: x.utcnow().timestamp())
```

```

dfClusters["ipStr"] = dfClusters["ip"]

#Convierto las IPs a datos continuos.
dfClusters["ip"] = dfClusters["ip"].apply(convertirIP)

sns.scatterplot(data=dfClusters,x="datetime", y="ip", color='#ef9f76')
plt.xlabel("Tiempo")
plt.ylabel("IPs")
plt.xticks([])
plt.yticks([])
plt.show()

```




Figure 12: IPs vs Tiempo

Como se puede observar en Figure 12 pareciese ser que a pesar de que se realizaron reportes en horarios distantes, las IPs no ocupan todo el espectro, solo rangos acotados, pudiendose interpretar que son distintos enrutadores de las mismas compañías.

Esto permite ver claramente la propiedad de ser “distribuidos”.

### 2.7.1 Veces que fueron utilizadas las IPs

```
print("Máximo numero de veces que se uso una IP: ",max(dfClusters["ipStr"].value_counts()))
```

Máximo numero de veces que se uso una IP: 1

Como podemos notar arriba, ninguna IP se usó más de una vez para enviar solicitudes al atacado.